

Classificação Multiclasse de Lesões da Mucosa Oral com Aprendizado Profundo em Imagens de Smartphone

Gustavo Novack Viana Lima, Henrick de Souza Silva,
André Moura Koraleski, Caio Lucca dos Santos Oliveira

¹ Instituto de Informática – Universidade Federal de Goiás (UFG)
Goiânia – GO – Brasil

{novack, henrick.henrick, andre.andre2, caiolucca}@discente.ufg.br

Abstract. *Oral cancer diagnosis remains late-stage in most cases, limiting five-year survival to below 50%. This work benchmarks three YOLO classification architectures (YOLOv8m-cls, YOLOv11m-cls, YOLO26m-cls) on the SMART-OM dataset — 2,469 annotated intraoral smartphone images across four diagnostic classes — against published deep learning baselines. Inverse-frequency loss weighting and oversampling address severe class imbalance (86.9% Normal). YOLO26m-cls surpasses the best baseline in macro sensitivity on the four-class task (69.57% vs. 61.57%, ResNet50) and on binary anomaly detection (66.15% vs. 65.62%, ResNet18).*

Resumo. *O diagnóstico do câncer oral ocorre predominantemente em estágio avançado, com sobrevida em cinco anos inferior a 50%. Este trabalho avalia três arquiteturas YOLO de classificação (YOLOv8m-cls, YOLOv11m-cls, YOLO26m-cls) no dataset SMART-OM — 2.469 imagens intraorais de smartphone em quatro classes diagnósticas — frente aos baselines publicados, com ponderação da loss por frequência inversa e oversampling para tratar o severo desbalanceamento (86,9% Normal). O YOLO26m-cls supera o melhor baseline em sensibilidade macro na tarefa multiclasse (69,57% vs. 61,57%, ResNet50) e na detecção binária de anomalias (66,15% vs. 65,62%, ResNet18).*

1. Introdução

O câncer oral (CO) representa um grave problema de saúde pública global. Segundo dados do GLOBOCAN 2020, cânceres de lábio e cavidade oral foram responsáveis por 177.757 mortes e 377.713 novos casos em todo o mundo, figurando como o 16º câncer mais incidente globalmente [Sung et al. 2021]. A sobrevida em cinco anos permanece inferior a 50%, pois a maioria dos diagnósticos ocorre em estágios avançados da doença. Condições precursoras — Desordens Potencialmente Malignas Orais (OPMD, do inglês *Oral Potentially Malignant Disorders*) — representam uma janela terapêutica crítica: a detecção precoce e a diferenciação de tecido saudável possibilita intervenção antes da progressão maligna.

O diagnóstico convencional baseia-se na inspeção visual por especialistas em patologia oral, processo inerentemente subjetivo e suscetível a variabilidade intra e interobservador. Em países de baixa e média renda, a concentração de especialistas nos grandes centros urbanos limita o acesso à triagem, resultando em diagnósticos tardios [Sung et al. 2021]. A maior parte dos *frameworks* de visão computacional para

lesões orais foi desenvolvida sobre imagens histopatológicas — que exigem biópsia e microscopia, incompatíveis com a atenção primária. Imagens capturadas por smartphones surgem como alternativa escalável e de baixo custo, mas a limitada disponibilidade de bases de dados públicas nessa modalidade restringiu o avanço da área.

Nesse contexto, Kumar et al. [Madan Kumar et al. 2026] introduziram o SMART-OM (*SMARTphone-based dataset of Oral Mucosa images*), o único dataset público de imagens intraorais identificado entre 332 disponíveis na área: 2.469 fotografias de 331 pacientes em quatro classes diagnósticas (Normal, Variação do Normal, OPMD e Câncer Oral), coletadas com smartphones Android e iOS em condições clínicas reais. Os autores estabeleceram um benchmark avaliando seis arquiteturas — ResNet18, ResNet34, ResNet50, VGG16, EfficientNet-b0 e Vision Transformer (ViT) [He et al. 2016, Tan and Le 2019, Dosovitskiy et al. 2020] — em detecção binária de anomalias e classificação multiclasse, atingindo 65,62% de sensibilidade para a classe Anormal (tarefa binária) e 61,57% de sensibilidade macro (multiclasse).

O presente trabalho propõe e avalia três arquiteturas YOLO no modo de classificação sobre o SMART-OM — YOLOv8m-cls, YOLOv11m-cls e YOLO26m-cls [Jocher et al. 2023, Jocher and Qiu 2024, Jocher and Qiu 2025] — como alternativa às CNNs clássicas e ao ViT do benchmark original. Como segunda contribuição, propomos um pipeline em dois estágios: detector binário de anomalias (Estágio 1) seguido de classificador de três classes (Estágio 2), com ponderação da função de perda por frequência inversa para mitigar o severo desbalanceamento do dataset.

2. Formulação do Problema

2.1. Definição da Tarefa

Dado um conjunto de imagens intraorais, o objetivo é aprender uma função f_θ que mapeie cada fotografia da mucosa oral a uma categoria diagnóstica. Avaliamos duas formulações complementares desta tarefa:

T₁ — Detecção binária de anomalias. Classificação em duas classes — *Normal* e *Anormal* — onde a segunda agrupa todas as imagens com alterações da mucosa (Variação do Normal, OPMD e Câncer Oral). O objetivo primário é maximizar a sensibilidade para a classe Anormal, minimizando falsos negativos: clinicamente, deixar escapar uma lesão tem consequências mais graves do que um falso alarme.

T₂ — Classificação multiclasse. Classificação em quatro classes: *Normal*, *Variação do Normal*, *OPMD* e *Câncer Oral*, replicando diretamente a tarefa do benchmark SMART-OM [Madan Kumar et al. 2026]. Esta formulação fornece maior granularidade diagnóstica, permitindo distinguir lesões potencialmente malignas (OPMD) de câncer já estabelecido, orientando decisões terapêuticas distintas.

2.2. Dataset

Utilizamos o dataset SMART-OM [Madan Kumar et al. 2026], composto por 2.469 imagens intraorais coletadas de 331 pacientes em condições clínicas reais, com smartphones Android e iOS, cobrindo oito regiões anatômicas da cavidade oral. A Tabela 1 apresenta a distribuição de imagens por classe e a partição treino/teste adotada (80%/20%, sem estratificação por paciente).

Tabela 1. Distribuição do dataset SMART-OM por classe.

Classe	Total	Treino [†]	Teste	% do total
Normal	2.145	1.716	429	86,9%
Variação do Normal	179	143	36	7,2%
OPMD	125	100	25	5,1%
Câncer Oral	20	16	4	0,8%
Total	2.469	1.975	494	100%

[†] Antes de *oversampling*; classes minoritárias são superamostradas no treinamento (Seção 3).

O dataset é severamente desbalanceado: Normal representa 86,9% das imagens e Câncer Oral apenas 0,8% (20 amostras), tornando a acurácia global inadequada como critério principal de avaliação.

2.3. Métricas de Avaliação

Em conformidade com o benchmark SMART-OM [Madan Kumar et al. 2026], reportamos para cada tarefa e modelo as seguintes métricas sobre o conjunto de teste:

- **Sensibilidade macro** (*macro recall*): média não ponderada da sensibilidade por classe — métrica primária, pois penaliza igualmente erros em classes raras e frequentes;
- **F1-score macro**: média harmônica de precisão e sensibilidade, calculada por classe e depois agregada por média simples;
- **Acurácia global, Precisão e Especificidade** — macro e por classe;
- **AUC-ROC** macro e por classe, calculada via *One-vs-Rest*.

A sensibilidade macro é adotada como critério de comparação principal com o baseline, dado o desbalanceamento do dataset e a assimetria clínica dos erros.

3. Metodologia

3.1. Preparação do Dataset

O dataset SMART-OM foi dividido aleatoriamente em 80% para treinamento e 20% para teste, sem estratificação por paciente ou por região intraoral, replicando o protocolo do benchmark de referência [Madan Kumar et al. 2026]. Não foi utilizado conjunto de validação separado, dado o reduzido número de amostras nas classes minoritárias — reservar uma terceira partição reduziria ainda mais os dados disponíveis para treinamento das classes OPMD (125 imagens) e Câncer Oral (20 imagens). E separar os dados do conjunto de treino tornaria as comparações inválidas para o protocolo de referência

Para mitigar o desbalanceamento severo (86,9% Normal), aplicamos *oversampling* por duplicação aleatória nas classes minoritárias do conjunto de treinamento, igualando a contagem de cada classe à maior entre elas. No conjunto de teste, nenhuma modificação é aplicada — as distribuições originais são preservadas para avaliação.

3.2. Arquiteturas Avaliadas

Avaliamos a variante *medium* de três famílias YOLO no modo de classificação, todas inicializadas com pesos pré-treinados no ImageNet e submetidas a *fine-tuning* no SMART-OM:

- **YOLOv8m-cls** [Jocher et al. 2023]: backbone CSPDarknet com módulos C2f;
- **YOLOv11m-cls** [Jocher and Qiu 2024]: evolução do YOLOv8 com módulos C3k2 e atenção espacial CBAM;
- **YOLO26m-cls** [Jocher and Qiu 2025]: arquitetura sem NMS, com *ProgLoss* e otimizador MuSGD para convergência estável.

Todo o treinamento foi realizado via framework Ultralytics com PyTorch [Jocher et al. 2023], em GPU NVIDIA RTX 4060 Laptop (8 GB VRAM).

3.3. Configuração de Treinamento

A Tabela 2 resume os hiperparâmetros utilizados, aplicados igualmente aos três modelos e às três tarefas de treinamento.

Tabela 2. Hiperparâmetros de treinamento.

Parâmetro	Valor
Épocas	100
Tamanho de batch	32
Tamanho de imagem	320 px
Otimizador	AdamW ($lr_0 = 10^{-3}$, $lr_f = 0,01$)
<i>Flip</i> horizontal	0,5
Rotação	$\pm 10^\circ$
Translação	10%
Escala	30%
Jitter de matiz	0,005
Jitter de saturação	0,7
Jitter de valor	0,4

3.4. Tratamento do Desbalanceamento via Loss Ponderada

Além do *oversampling*, aplicamos ponderação de classes na função de perda durante o treinamento. Os pesos são calculados pelo método de frequência inversa normalizada:

$$w_c = \frac{N}{C \cdot n_c}, \quad w_c \leftarrow \frac{w_c}{\bar{w}} \quad (1)$$

onde N é o total de amostras de treinamento, C é o número de classes e n_c é o número de amostras da classe c . A normalização pela média $\bar{w}$ mantém a escala da loss equivalente ao caso sem ponderação, preservando o *learning rate* calibrado.

3.5. Pipeline de Dois Estágios

Como contribuição adicional, propomos um pipeline de classificação em dois estágios sequenciais:

Estágio 1 — Detector binário. Um classificador treinado na tarefa T_1 (Normal vs. Anormal) recebe a imagem e decide se há alguma alteração da mucosa. Caso a imagem seja classificada como Normal, o pipeline encerra. Caso contrário, ela é encaminhada ao Estágio 2.

Estágio 2 — Classificador de lesões. Um segundo classificador, treinado exclusivamente sobre as 760 imagens anômalas (Variação do Normal, OPMD e Câncer Oral) após *oversampling*, distingue entre as três categorias patológicas.

A avaliação do pipeline é feita de forma *end-to-end*: imagens incorretamente classificadas como Normal pelo Estágio 1 nunca chegam ao Estágio 2, sendo contabilizadas como erro na métrica final de quatro classes.

4. Resultados e Discussão

4.1. Detecção Binária de Anomalias (T_1)

A Tabela 3 apresenta os resultados completos na tarefa binária, comparando o melhor modelo do benchmark SMART-OM (ResNet18 [Madan Kumar et al. 2026]) com os três modelos propostos. Em negrito, o melhor valor por linha entre todos os modelos.

Tabela 3. Desempenho na classificação binária (T_1). Em negrito: melhor valor por linha. Baseline: ResNet18 [Madan Kumar et al. 2026].					
Métricas de Desempenho		ResNet18	YOLOv8m	YOLOv11m	YOLO26m
Acurácia (%)		90,89	92,11	91,90	93,32
Média Macro	Precisão (%)	79,74	84,20	83,22	87,31
	Sensibilidade (%)	80,14	79,14	79,67	81,79
	Especificidade (%)	80,14	79,14	79,67	81,79
	F1-Score (%)	79,94	81,37	81,30	84,24
	AUC	0,91	0,91	0,88	0,87
Métricas (Normal)	Precisão (%)	94,87	94,32	94,51	95,00
	Sensibilidade (%)	94,65	96,74	96,27	97,44
	Especificidade (%)	65,62	61,54	63,08	66,15
	F1-Score (%)	94,76	95,51	95,38	96,20
Métricas (Anormal)	Precisão (%)	64,61	74,07	71,93	79,63
	Sensibilidade (%)	65,62	61,54	63,08	66,15
	Especificidade (%)	94,65	96,74	96,27	97,44
	F1-Score (%)	65,12	67,23	67,21	72,27

O YOLO26m-cls superou o ResNet18 em quase todas as métricas, com destaque para precisão macro (+7,57 p.p.), F1-macro (+4,30 p.p.) e sensibilidade da classe Anormal (66,15% vs. 65,62%). O único indicador em que o baseline se mantém superior é a AUC (0,91 vs. 0,87), sugerindo que a discriminação global de ranking é ligeiramente melhor no ResNet18, enquanto o YOLO26m-cls toma decisões binárias mais precisas. A

Figura 1 exibe a matriz de confusão do YOLO26m-cls: 97,44% das imagens Normais são classificadas corretamente, com 33,85% de falsos negativos na classe Anormal. A Figura 2 compara a sensibilidade macro de todos os modelos nas duas tarefas.

YOLOv8m-cls e YOLOv11m-cls mantiveram-se próximos ao ResNet18 em sensibilidade macro (79,14% e 79,67%, respectivamente, contra 80,14% do baseline), com ganho de F1-macro em ambos os casos (+1,43 e +1,36 p.p.). O ganho de sensibilidade na classe Anormal obtido pelo YOLO26m-cls — ainda que de apenas 0,53 p.p. em termos absolutos — tem relevância clínica direta: em contexto de triagem, cada caso Anormal classificado erroneamente como Normal representa um paciente que não é encaminhado para avaliação especializada, podendo ter sua janela de intervenção precoce comprometida.




Figura 1. Matriz de confusão do YOLO26m-cls na tarefa binária (T_1).




Figura 2. Sensibilidade macro dos modelos propostos vs. baseline do SMART-OM nas tarefas binária (a) e multiclasse (b). A linha tracejada indica o melhor resultado do benchmark.

Tabela 4. Desempenho na classificação multiclasse (T_2). Em negrito: melhor valor por linha. Baseline: ResNet50 [Madan Kumar et al. 2026].

Métricas de Desempenho		ResNet50	YOLOv8m	YOLOv11m	YOLO26m
Acurácia (%)		89,07	91,30	90,08	90,69
Média Macro	Precisão (%)	74,62	81,41	77,86	77,13
	Sensibilidade (%)	61,57	57,06	52,94	69,57
	Especificidade (%)	84,63	89,42	87,11	89,92
	F1-Score (%)	65,99	61,36	58,80	71,46
	AUC	0,91	0,92	0,92	0,93
Métricas (Normal)	Precisão (%)	91,83	94,38	93,10	94,75
	Sensibilidade (%)	96,74	97,90	97,44	96,74
	Especificidade (%)	42,19	61,54	52,31	64,62
	F1-Score (%)	94,22	96,11	95,22	95,73
Métricas (Variação)	Precisão (%)	40,00	75,00	60,00	57,89
	Sensibilidade (%)	16,22	33,33	33,33	30,56
	Especificidade (%)	98,03	99,13	98,25	98,25
	F1-Score (%)	23,08	46,15	42,86	40,00
Métricas (OPMD)	Precisão (%)	66,67	56,25	58,33	55,88
	Sensibilidade (%)	66,67	72,00	56,00	76,00
	Especificidade (%)	98,30	97,01	97,87	96,80
	F1-Score (%)	66,67	63,16	57,14	64,41
Métricas (Câncer Oral)	Precisão (%)	100,00	100,00	100,00	100,00
	Sensibilidade (%)	66,67	25,00	25,00	75,00
	Especificidade (%)	100,00	100,00	100,00	100,00
	F1-Score (%)	80,00	40,00	40,00	85,71

4.2. Classificação Multiclasse (T_2)

A Tabela 4 detalha os resultados completos por classe na tarefa de quatro categorias, tendo como baseline o ResNet50 [Madan Kumar et al. 2026] — o melhor modelo reportado pelo benchmark original nessa tarefa. A classificação multiclasse é substancialmente mais desafiadora que a tarefa binária: além do desbalanceamento geral, as classes OPMD (5,1%) e Câncer Oral (0,8%) apresentam características visuais sutis e contagens de teste reduzidas, tornando a sensibilidade macro o critério mais informativo para comparação entre modelos.

O YOLO26m-cls foi o único modelo proposto a superar o ResNet50 na métrica primária, com sensibilidade macro de 69,57% contra 61,57% do baseline (+8,0 p.p.), além de F1-macro superior (+5,47 p.p.) e maior AUC (0,93 vs. 0,91). YOLOv8m-cls e YOLOv11m-cls ficaram abaixo do ResNet50 em sensibilidade macro (57,06% e 52,94%, respectivamente), demonstrando que o ganho não é uniforme na família YOLO e está concentrado na arquitetura mais recente. Na classe OPMD — clinicamente crítica por representar a janela de intervenção pré-maligna — o YOLO26m-cls atingiu 76,00% de sensibilidade contra 66,67% do baseline.




Figura 3. Matriz de confusão do YOLO26m-cls na tarefa multiclasse (T_2).

4.3. Pipeline de Dois Estágios (T_2)

A Tabela 5 compara o pipeline de dois estágios com as abordagens *one-stage* e o baseline do SMART-OM na tarefa de classificação multiclasse. O pipeline combina o melhor detector binário (YOLO26m-cls) com o melhor classificador de lesões (YOLOv8m-cls no estágio 2), selecionados individualmente por sensibilidade macro em seus respectivos conjuntos de validação.

Tabela 5. Comparação entre abordagens na tarefa multiclasse (T_2). Em negrito: melhor valor por linha. Two-Stage: YOLO26m-cls (binário) + YOLOv8m-cls (lesões).

Métricas de Desempenho		ResNet50	YOLOv8m	YOLOv11m	YOLO26m	Two-Stage
Acurácia (%)		89,07	91,30	90,08	90,69	91,90
Média Macro	Sensibilidade (%)	61,57	57,06	52,94	69,57	71,83
	F1-Score (%)	65,99	61,36	58,80	71,46	74,94
	AUC	0,91	0,92	0,92	0,93	0,83
Sensibilidade por Classe (%)	Normal	96,74	97,90	97,44	96,74	97,44
	Variação	16,22	33,33	33,33	30,56	38,89
	OPMD	66,67	72,00	56,00	76,00	76,00
	Câncer Oral	66,67	25,00	25,00	75,00	75,00

Baseline ResNet50 de [Madan Kumar et al. 2026]; modelos YOLO treinados neste trabalho.

O pipeline de dois estágios obteve a maior sensibilidade macro (71,83%) e o maior F1-macro (74,94%) entre todas as abordagens avaliadas, superando o melhor modelo *one-stage* (YOLO26m, 69,57%) em 2,26 p.p. e o baseline em 10,26 p.p. A Variação do Normal registrou a maior sensibilidade de todos os métodos (38,89%), beneficiada pela especialização do Estágio 2 em distinguir apenas entre categorias patológicas.

A AUC do pipeline (0,83) ficou substancialmente abaixo dos modelos *one-stage* (0,92–0,93). Essa queda é estrutural: a AUC avalia a qualidade do *ranking* de probabilidades, e no pipeline de dois estágios as probabilidades dos dois estágios não são calibradas em escala comum.

4.4. Discussão

Os resultados revelam um panorama nuançado. O YOLO26m-cls é o modelo com melhor desempenho *one-stage* nas métricas clinicamente mais relevantes — sensibilidade macro (+8,0 p.p. sobre o ResNet50) e F1-macro (+5,47 p.p.). O pipeline de dois estágios vai além, atingindo 71,83% de sensibilidade macro e 74,94% de F1-macro — os melhores valores entre todas as abordagens avaliadas — ao custo de maior complexidade de implantação e de uma AUC degradada pela falta de calibração entre estágios. YOLOv8m-cls e YOLOv11m-cls ficam abaixo do ResNet50 em sensibilidade macro *one-stage*, evidenciando que o ganho não é universal à família YOLO, mas concentrado na arquitetura YOLO26m.

Na tarefa binária, o YOLO26m-cls também lidera, superando o ResNet18 em todas as métricas exceto AUC (0,87 vs. 0,91). Isso indica que o modelo produz probabilidades menos calibradas para ranking, mas toma decisões de limiar com maior precisão.

A classe *Varição do Normal* permanece o principal gargalo em todos os modelos avaliados, incluindo o baseline (sensibilidade de 16–43% no *one-stage*). Suas imagens partilham características visuais com as demais classes, tornando-a intrinsecamente difícil de separar sem informação adicional. A classe *Câncer Oral*, com apenas 4 amostras de teste, apresenta alta variância — o YOLO26m-cls e o pipeline acertam 3/4 (75%) esses números devem ser interpretados com cautela dado o tamanho ínfimo da partição.

5. Conclusão

Este trabalho avaliou três arquiteturas YOLO modernas no modo de classificação — YOLOv8m-cls, YOLOv11m-cls e YOLO26m-cls — sobre o dataset público SMART-OM [Madan Kumar et al. 2026], em duas tarefas: detecção binária de anomalias (T_1) e classificação multiclasse de quatro categorias diagnósticas (T_2). O critério de sucesso estabelecido nos objetivos foi atingido: o YOLO26m-cls superou o benchmark original em ambas as tarefas, alcançando 66,15% de sensibilidade na classe Anormal contra 65,62% do ResNet18 na tarefa binária, e 69,57% de sensibilidade macro contra 61,57% do ResNet50 na tarefa multiclasse — um ganho de 8,0 p.p. na métrica primária. O F1-macro também melhorou em ambas as tarefas (+4,30 p.p. em T_1 e +5,47 p.p. em T_2).

Esses resultados demonstram que arquiteturas concebidas para detecção em tempo real, quando adaptadas à tarefa de classificação e treinadas com ponderação de classes, são competitivas com CNNs clássicas em cenários clínicos desbalanceados. A ponderação por frequência inversa e o *oversampling* mostraram-se particularmente eficazes para a classe Câncer Oral (sensibilidade de 75% com YOLO26m-cls contra 66,67% do ResNet50), apesar das apenas 4 amostras de teste disponíveis. Contudo, a família YOLO não apresentou ganhos uniformes: YOLOv8m-cls e YOLOv11m-cls ficaram abaixo do ResNet50 em sensibilidade macro na tarefa multiclasse, e o YOLO26m-cls perdeu em AUC na tarefa binária (0,87 vs. 0,91), indicando que a calibração de probabilidades permanece um ponto de atenção.

O trabalho apresenta limitações que devem ser consideradas na interpretação dos resultados. A classe Câncer Oral conta com apenas 20 imagens no total e 4 no conjunto de teste, tornando suas métricas altamente sensíveis a predições individuais. A classe Variação do Normal permanece o principal gargalo — com sensibilidade entre 16% e 43% em todos os modelos avaliados, inclusive no baseline — sugerindo que suas características visuais se sobrepõem às demais classes de forma intrínseca.

Como trabalhos futuros, destacam-se: (i) adotar validação cruzada estratificada para produzir estimativas de desempenho mais robustas e comparáveis ao benchmark; (ii) investigar estratégias de *data augmentation* específicas para imagens intraorais, como transformações de cor controladas que preservem as propriedades diagnósticas da mucosa; e (iii) explorar técnicas de explicabilidade — como mapas de ativação Grad-CAM — para identificar as regiões da imagem que sustentam as predições e aumentar a confiança clínica nos modelos.

Referências

- [Dosovitskiy et al. 2020] Dosovitskiy, A., Beyer, L., Kolesnikov, A., Weissenborn, D., Zhai, X., Unterthiner, T., Dehghani, M., Minderer, M., Heigold, G., Gelly, S., Uszkoreit, J., and Houlsby, N. (2020). An image is worth 16x16 words: Transformers for image recognition at scale. *arXiv preprint arXiv:2010.11929*.
- [He et al. 2016] He, K., Zhang, X., Ren, S., and Sun, J. (2016). Deep residual learning for image recognition. In *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 770–778.
- [Jocher et al. 2023] Jocher, G., Chaurasia, A., and Qiu, J. (2023). Ultralytics YOLOv8. Version 8.0.0. License: AGPL-3.0.
- [Jocher and Qiu 2024] Jocher, G. and Qiu, J. (2024). Ultralytics YOLO11. License: AGPL-3.0.
- [Jocher and Qiu 2025] Jocher, G. and Qiu, J. (2025). YOLO26: Key architectural enhancements and performance benchmarking for real-time object detection. *arXiv preprint arXiv:2509.25164*.
- [Madan Kumar et al. 2026] Madan Kumar, P. D., Ranganathan, K., Lavanya, C., Rajeshwari, S., Nayak, A., Kestur, R., Diddigi, R. B., and Behera, S. S. (2026). A smartphone-based comprehensive dataset of annotated oral cavity images for enhanced oral disease diagnosis. *Scientific Data*, 13:676.
- [Sung et al. 2021] Sung, H., Ferlay, J., Siegel, R. L., Laversanne, M., Soerjomataram, I., Jemal, A., and Bray, F. (2021). Global cancer statistics 2020: GLOBOCAN estimates of incidence and mortality worldwide for 36 cancers in 185 countries. *CA: A Cancer Journal for Clinicians*, 71(3):209–249.
- [Tan and Le 2019] Tan, M. and Le, Q. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. In *Proceedings of the 36th International Conference on Machine Learning (ICML)*, volume 97 of *Proceedings of Machine Learning Research*, pages 6105–6114.